

extremalstellen

1. Stationary points

$$f(x, y, z) = \ln(x) - x + xy + y^2 - yz$$

↳ ableiten für alle parameter

→ gleichungssystem lösen

$$\partial_x f = f_x = \frac{1}{x} - 1 + y$$

$$y = 0$$

$$\partial_y f = f_y = 2y + x - z$$


$$\frac{1}{x} = 1 \rightarrow x = 1$$

$$\partial_z f = f_z = -y$$

$$1 - z = 0 \rightarrow z = 1$$

$P(1, 0, 1)$ is stationary

2. local extremal points



$$f: [c, b] \rightarrow \mathbb{R}$$

1.) $f'(x) = 0 \rightarrow$ stationary points
 $\rightarrow x_1, x_2, x_3$

2.) $f''(x) \rightarrow$ hesse matrix

falls $f''(x_1) < 0 \rightarrow x_1$ ist lokal ein max.

falls $f''(x_2) > 0 \rightarrow x_2$ ist lok. ein min.

$$\partial_{xx} = -\frac{2}{x^2} + \frac{1}{(z-x)^2}$$

$$\partial_{xy} = 0$$

$$\partial_{xz} = -\frac{1}{(z-x)^2}$$

$$\partial_{yy} = -\frac{1}{2y^2}$$

$$\partial_{yz} = 0$$

$$\partial_{zz} = \frac{1}{(z-x)^2}$$

$$H = \begin{pmatrix} -\frac{2}{x^2} + \frac{1}{(z-x)^2} & 0 & -\frac{1}{(z-x)^2} \\ 0 & -\frac{1}{2y^2} & 0 \\ \frac{1}{(z-x)^2} & 0 & \frac{1}{(z-x)^2} \end{pmatrix} = \begin{pmatrix} \frac{1}{2} & 0 & -1 \\ 0 & -2 & 0 \\ -1 & 0 & 1 \end{pmatrix}$$

$$\frac{1}{2}v_1^2 - 2v_2^2 + v_3^2 - 2v_1v_3 = ((v_1+v_3)^2 - \frac{1}{2}v_1^2) - 2v_2^2$$

Sattelpunkt: +/- vorhanden

Max.: alles minus

Min.: alles plus

Other stuff

$$h(x) = g \circ f = g(f(x)), \text{ chain rule: } J_h(x) = J_g(f(x)) \cdot J_f(x)$$

$$q = h \circ g \circ f \rightarrow \frac{\partial}{\partial q} = J_h(g) \cdot J_g(f) \cdot J_f(\vec{x})$$

derivative of matrices / proofs / affine transformations

a.) $f(\vec{x}) = \vec{x} \cdot \vec{A}$, $\vec{E}_{ij} = \begin{cases} 1 & \text{if } i=j \\ 0 & \text{else} \end{cases}$ $\xrightarrow{\text{partial derivative}} (\vec{E}_{ij})_{kr} = \delta_{ik} \delta_{jr}$

Kronecker delta

$$\delta_{ij} = \begin{cases} 0 & \text{if } i \neq j \\ 1 & \text{if } i = j \end{cases}$$

Proof: $\frac{\partial}{\partial x_{ij}} f(\vec{x}) = \vec{E}_{ij} \cdot \vec{A}$

$$\frac{\partial}{\partial x_{ij}} f_{kl}(\vec{x}) = \frac{\partial}{\partial x_{ij}} \sum_r x_{kr} a_{rl} = \sum_r \delta_{ik} \delta_{jr} a_{rl} = \delta_{ik} a_{jl} = (\vec{E}_{ij} \cdot \vec{A})_{kl}$$

b.) $f_i: \begin{cases} \mathbb{R}^n \rightarrow \mathbb{R}^n \\ \vec{x} \mapsto \vec{M}_i \cdot \vec{x} + \vec{b}_i \end{cases}$ with $M_i \in \mathbb{R}^{n \times n}$ and $b_i \in \mathbb{R}^n$

$$A(\vec{x}) = M \cdot \vec{x} + \vec{b}$$

$$J_A(\vec{x}) = \nabla A = M$$

$$\mathbb{R}^n \xrightarrow{f_1} \mathbb{R}^n \xrightarrow{f_2} \mathbb{R}^n \xrightarrow{f_3} \dots \xrightarrow{f_n} \mathbb{R}^n$$

Proof: $J_{f_i}(x) = M_i$

calculate $J_g(x)$: $g(x) = f_n(\dots(f_2(f_1(x))))$

$$J_g = J_{f_n} \cdot J_{f_{n-1}} \cdots J_{f_2} \cdot J_{f_1} = M_n \cdot M_{n-1} \cdots M_2 \cdot M_1$$

Maximum likelihood $\rightarrow$ estimate parameters of probability distribution

$$l(a, b) = \left(\prod_{x \in S_{\text{day}}} p_{m, q}(b(x)) \right) \left(\prod_{x \in S_{\text{night}}} (1 - p_{m, q}(b(x))) \right) = p^n (1-p)^{\text{total}-n}$$

log-likelihood (cost function) $\rightarrow$ everything in product form can be in log form

$$\ln l(a, b) = \sum_{x \in S_{\text{day}}} \ln [p_{m, q}(b(x))] + \sum_{x \in S_{\text{night}}} \ln [1 - p_{m, q}(b(x))]$$

We use negative-log-likelihood as a cost function for logistic regression
 $\rightarrow$ this gives us the minimal cost (which is desired for ML)

$$C(m, q) = -\ln l(a, b) = - \left[\sum_{x \in S_{\text{day}}} \ln [p_{m, q}(b(x))] + \sum_{x \in S_{\text{night}}} \ln [1 - p_{m, q}(b(x))] \right]$$

to find max./min. points the derivative needs to be set to 0.

$$\frac{\partial}{\partial p} [-\ln l(p)] = 0$$

e.g: $p = \frac{35}{100}$

gradient:

$$|V| = \sqrt{V_1^2 + V_2^2}$$

$$\nabla \ln\left(\frac{x^2 \cos y}{e^z}\right) \rightarrow \text{derive for } x, y, z$$

$$\nabla e^{-|\vec{r}|^2} = e^{-|\vec{r}|^2} \cdot -2|\vec{r}| \cdot \frac{\vec{r}}{|\vec{r}|} = e^{-|\vec{r}|^2} \cdot -2\vec{r}$$

$$\nabla(\vec{x}^T \cdot \vec{x}) = \nabla |x|^2 = 2 \cdot |\vec{x}|^2 \cdot \frac{\vec{x}}{|\vec{x}|} = 2\vec{x}$$

$$\nabla |V| = \frac{V^T}{|V|} \quad |x|^2 = \sum_{i=1}^n x_i^2$$

$$u \cdot v = u^T v = \sum_k u_k v_k$$

$$\nabla(u \cdot v) = v^T u^T$$

partial derivative:

Kronecker delta:
ensures only
part where $i=k$
survives

$$a.) \frac{\partial}{\partial r_k} \sum_i e^{r_i} \cdot \ln r_i = \sum_i \frac{\partial}{\partial r_k} e^{r_i} \cdot \ln r_i = \sum_i (e^{r_i} \cdot \ln r_i + e^{r_i} \cdot \frac{1}{r_i}) \delta_{ik} = e^{r_k} \cdot (\ln r_k + \frac{1}{r_k})$$

$\rightarrow$ all derivatives where $i \neq k$ are 0

$$b.) f(x, y) = t^2 x^2 \sin(tx)$$

$$x(t) = \frac{e^t}{t}$$

Negative definit: $H(x, y)$ all values -
Positive definit: $H(x, y)$ all values +
Indefinite: mixed +/-

$\rightarrow$ partial integral, don't insert $x(t)$

$\rightarrow$ derivative, insert $x(t)$

$$i.) \frac{\partial}{\partial t} f(x, t) = \frac{\partial}{\partial t} (t^2 x^2 \sin(tx)) = 2tx^2 \sin(tx) + t^2 x^2 \cos(tx) = t x^2 (2 \sin(tx) + t x \cos(tx))$$

$$ii.) \frac{d}{dt} f(x, t) = \frac{d}{dt} \left(t^2 \cdot \left(\frac{e^t}{t} \right)^2 \cdot \sin\left(t \cdot \frac{e^t}{t}\right) \right) = \frac{d}{dt} (e^{2t} \cdot \sin(e^t)) = 2e^{2t} \cdot \sin(e^t) + e^{2t} \cdot e^t \cos(e^t) = e^{2t} (2 \sin(e^t) + e^t \cos(e^t))$$

Stationary points

$$f(\vec{x}) = \ln(x_1 \cdot x_2 \cdot x_3 \cdots x_n) - \sum_{i=1}^n x_i^2 = \nabla \sum_{i=1}^n i \cdot \ln(x_i) - x_i^2 = 0$$

$\rightarrow$ write vector in components to make simpler

$$= \frac{i}{x_i} - 2x_i = 0 \quad \text{for } i=1, \dots, n \rightarrow \begin{aligned} i - 2x_i^2 &= 0 \\ i &= 2x_i^2 \\ \frac{i}{2} &= x_i^2 \\ \sqrt{\frac{i}{2}} &= x_i \end{aligned}$$

$$\vec{x} = \begin{pmatrix} \sqrt{\frac{1}{2}} \\ \sqrt{\frac{2}{2}} \\ \sqrt{\frac{3}{2}} \\ \vdots \\ \sqrt{\frac{n}{2}} \end{pmatrix}$$

linearisation

$$f(x, y, z) = \begin{pmatrix} x^2 \sin(y) \\ y + \cos(x-z) \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

$$J_f = \begin{pmatrix} 2x \sin(y) & x^2 \cos(y) & 0 \\ -\sin(x-z) & 1 & \sin(x-z) \end{pmatrix} = J_f(1, 0, 1) = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 1 & 0 \end{pmatrix}$$

at $(x, y, z) = (1, 1, -0.9, 0.9) \rightarrow$ use $(1, 0, 1)$ to simplify

$$L(x) = f(x_0) + J_f(x_0)(x - x_0) \stackrel{!}{=} 0$$

$$f(1, 1, -0.1, 0.9) \approx f(1, 0, 1) + J_f(1, 0, 1) \left[\begin{pmatrix} 1.1 \\ -0.1 \\ 0.9 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} \right] \approx \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \begin{pmatrix} 0 & 1 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 0.1 \\ -0.1 \\ -0.1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \begin{pmatrix} -0.1 \\ -0.1 \end{pmatrix} = \begin{pmatrix} -0.1 \\ 0.9 \end{pmatrix}$$

probability density functions (PDF) → derivative of CDF
 how probable is the occurrence of x

given: $f_x(x) = \frac{1}{\mathcal{I}_{[0;\infty)}}(x) \cdot e^{-x}$

$Y = \sigma(x)$

$\sigma(x) = \frac{1}{1+e^{-x}}$

$|f_y(y) dy| = |f_x(x) dx|$

$f_y(y) = f_x(x) \cdot \frac{dx}{dy}$

→ applies if strictly
 monotonic $g'(x) > 0 \vee < 0$
 else: calculate $F(x)$
 → differentiate

1. invert sigmoid $\sigma(x) \rightarrow \frac{1}{y} = 1 + e^{-x} \rightarrow \frac{1}{y} - 1 = e^{-x} \rightarrow -\ln\left(\frac{1}{y} - 1\right) = x = g^{-1}(y)$

2. derivative of the inverse: $-\frac{1}{\frac{1}{y}-1} \cdot -\frac{1}{y^2} = \frac{1}{\frac{y^2}{y}-y^2} = \frac{1}{y-y^2}$

3. apply: $f_y(y) = \frac{1}{\mathcal{I}_{[0;\infty)}}(x) \cdot e^{-x} \cdot \frac{1}{y-y^2}$
 $= \frac{1}{\mathcal{I}_{[0;\infty)}}\left(-\ln\left(\frac{1}{y}-1\right)\right) \cdot e^{\ln\left(\frac{1}{y}-1\right)} \cdot \frac{1}{y-y^2} = \frac{1}{y^2} \frac{1}{\mathcal{I}_{[0;\infty)}}\left(-\ln\left(\frac{1}{y}-1\right)\right)$

4. solve $g^{-1}(x) \geq 0$

$-\ln\left(\frac{1}{y}-1\right) \geq 0$
 $\frac{1}{y}-1 \leq 1$
 $\frac{1}{y} \leq 2$
 $y \geq \frac{1}{2}$

$f_y(y) = \frac{1}{y^2} \frac{1}{\mathcal{I}_{[\frac{1}{2};1)}}(y)$

Sigmoid function

$\sigma = \begin{cases} \mathbb{R} \rightarrow (0;1) & \text{larger input} \\ t \mapsto \frac{1}{1+e^{-t}} & = \text{output closer to 1} \end{cases}$

Normal distribution / gaussian distribution

$f(x) = \frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$ $\mu = \text{mean value}$
 $\sigma = \text{standard deviation}$
 global max.: $\sigma = \mu$

Let $X \sim \mathcal{N}(\mu; \sigma^2)$, $X = Y^3 + 2Y = g(Y)$
 find $f_y(y)$ $\rightarrow$ if Y here solve for X
 $g'(Y) = 3Y^2 + 2 > 0$

$f_y(y) = f_x(x) \cdot \frac{dx}{dy} = f_x(g(y)) \cdot g'(y) = \frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{1}{2\sigma^2}(g(y)-\mu)^2} \cdot (3y^2+2)$
 $= \frac{1}{\sqrt{8\pi}} e^{-\frac{1}{8}(y^3+2y-1)^2} \cdot (3y^2+2)$

Commutative distribution
 function (CDF)

→ probability of interval
 discrete probability distribution
 → finite sample space, sum of all
 probabilities of events = 1

Probability

Sample space Ω : Set of all possible outcomes → $\Omega = \{h, t\}$

event: any subset of the sample space

Probability measure: probability for an event to occur

Indicator function: random variable that takes value 1 when the event happens and value 0 when it doesn't.

Domain: set of all subsets E

AXIOME von KOLOMOGOROV

Ω ein Grundraum und $A \subset \Omega$

1.) $IP(A) \geq 0$

2.) $IP(\Omega) = 1$

3.) $IP(A \cup B) = IP(A) + IP(B)$ falls $A \cap B = \emptyset$

BSP: $\Omega = \{1, \dots, 6\}$, $A = \{2, 4, 6\}$, $B = \{1\}$

$IP(A \cup B) = IP(A) + IP(B) = \frac{3}{6} + \frac{1}{6} = \frac{4}{6}$

example: P of 60% head
discrete probability distribution:

$$p: \begin{cases} \Omega \rightarrow [0; 1] \\ x \mapsto \begin{cases} 0.6 & \text{if } x = h \\ 0.4 & \text{if } x = t \end{cases} \end{cases}$$

commutative distribution function:

$$F: \begin{cases} \mathbb{R} \rightarrow [0; 1] \\ x \mapsto \begin{cases} 0 & \text{for } x < 0 \\ 0.6 & \text{for } 0 \leq x < 1 \\ 1 & \text{for } x \geq 1 \end{cases} \end{cases}$$

indicator function:

$$F(x) = 0.6 \cdot 1_{[0; 1)} + 1_{[1; \infty)}$$

Uniform Probability distribution (unif)

Let $X \sim \text{unif}(0; 3)$, $Y = X^2 + 2X = g(X)$ $f_X(x) = F'_X(x) = \begin{cases} \frac{1}{3} & \text{for } x \in (0; 3) \\ 0 & \text{for } x < 0 \vee x > 3 \end{cases}$

$\hookrightarrow$ random variable X is uniformly distributed in interval $[0; 3]$

Since it is uniform, we conclude that: density of uniform is constant

$F_X(x) = 0$ for $x \leq 0$

$F_X(x) = 1$ for $x \geq 3$

(straight line): $F_X = mx + b$

$F_X(0) = 0 \rightarrow b = 0$

$F_X(3) = 1 \rightarrow m \cdot 3 = 1 \rightarrow m = \frac{1}{3}$

$F_X(x) = \frac{1}{3}x$

indicator function:

$F_X(x) = \frac{1}{3}x \cdot 1_{[0; 3)}(x) + 1_{(3; \infty)}(x)$ $\rightarrow f_X(x) = \frac{1}{3} \cdot 1_{[0; 3)}(x)$

$\hookrightarrow$ does not matter, can be dropped

for F_Y and f_Y : invert $Y \rightarrow -1 - \sqrt{y+1} \leq x \leq -1 + \sqrt{y+1}$

Min: $X=0 \rightarrow Y=0$

Max: $X=3 \rightarrow Y=3^2+2 \cdot 3=15$

$F_Y(y) = \int_{-1-\sqrt{y+1}}^{-1+\sqrt{y+1}} f_X(x) dx = \int_0^{-1+\sqrt{y+1}} \frac{1}{3} \cdot 1_{[0; 3)}(x) dx = \frac{-1+\sqrt{y+1}}{3}$ for $y \in [0; 15]$

0 because $x \in [0; 3]$

indicator function: $F_Y(y) = \frac{-1+\sqrt{y+1}}{3} \cdot 1_{[0; 15]}(y) + 1_{(15; \infty)}(y)$

$f_Y(y) = \frac{\partial}{\partial y} \left(\frac{-1+\sqrt{y+1}}{3} \right) \cdot 1_{[0; 15]}(y) = \frac{1}{6\sqrt{y+1}} \cdot 1_{[0; 15]}(y)$

Method without integral: $X \sim \text{unif}(1, 3)$, $Y = \sqrt[3]{\frac{5-X}{2}}$ $X = 5 - 2Y^3$

$f_X(x) = \frac{1}{2} \cdot 1_{(1; 3)}(x) \rightarrow f_Y(y) = -f_X(g(y)) \cdot g'(y)$

$\rightarrow g'(y) = -6y^2 < 0$

$f'_Y(y) = -\frac{1}{2} \cdot 1_{(1; 3)}(5-2y^3) \cdot (-6y^2) = 3y^2 \cdot 1_{(1; 3)}(5-2y^3)$

$\rightarrow \begin{cases} 3y^2 & \text{if } 1 < y < \sqrt[3]{2} \\ 0 & \text{else} \end{cases}$

$g(x) = 1 \rightarrow \sqrt[3]{2}$ $\hookrightarrow f_Y(y) = 3y^2 \cdot 1_{(1, \sqrt[3]{2})}(y)$

$g(x) = 3 \rightarrow 1$

$\begin{cases} m + b = 0 \\ 3m + b = 1 \end{cases} \mid m = \frac{1}{2}$

chain rule / commutative diagram

$$f(x, y) = k(h(g(x, y)))$$

$$f(x, y) = \begin{pmatrix} \cos(xy^2) + \sin(xy^2) \\ \ln(xy^2) \end{pmatrix} = \begin{pmatrix} \cos(xy^2) + \sin(xy^2) \\ \ln(x) + 2\ln(y) \end{pmatrix}$$

$$J_f(x, y) = \begin{pmatrix} -\sin(xy^2)y^2 + \cos(xy^2)y^2 & -\sin(xy^2) \cdot 2yx + \cos(x)2yx \\ \frac{1}{x} & \frac{2}{y} \end{pmatrix}$$

$$J_f(\pi, 1) = \begin{pmatrix} -\sin(\pi) + \cos(\pi) & -\sin(\pi) \cdot 2\pi + \cos(\pi)2\pi \\ \frac{1}{\pi} & 2 \end{pmatrix} = \begin{pmatrix} -1 & -2\pi \\ \frac{1}{\pi} & 2 \end{pmatrix}$$

$$\begin{array}{ccc} (\mathbb{R}^+)^2 & \xrightarrow{f} & \mathbb{R}^2 \\ g \downarrow & & \uparrow k \\ \mathbb{R}^+ & \xrightarrow{h} & \mathbb{R}^2 \times \mathbb{R}^+ \end{array}$$

Basics	
Ableitungen	
$\frac{d}{dx}(x^a) = a \cdot x^{a-1}$	$\frac{d}{dx} \log_b(x) = \frac{1}{\ln(b) \cdot x}$
$\frac{d}{dx}(1) = 0$	$\frac{d}{dx} \sin(x) = \cos(x)$
$\frac{d}{dx}(x) = 1$	$\frac{d}{dx} \cos(x) = -\sin(x)$
$\frac{d}{dx}(x^2) = 2x$	$\frac{d}{dx} \tan(x) = \frac{1}{\cos^2(x)}$
$\frac{d}{dx}\left(\frac{1}{x}\right) = -\frac{1}{x^2}$	$\frac{d}{dx} \tan(x) = 1 + \tan^2(x)$
$\frac{d}{dx}(\sqrt{x}) = \frac{1}{2\sqrt{x}}$	$\frac{d}{dx} \arcsin(x) = \frac{1}{\sqrt{1-x^2}}$
$\frac{d}{dx}(e^x) = e^x$	$\frac{d}{dx} \arccos(x) = -\frac{1}{\sqrt{1-x^2}}$
$\frac{d}{dx}(a^x) = \ln(a) \cdot a^x$	$\frac{d}{dx} \arctan(x) = \frac{1}{1+x^2}$
$\frac{d}{dx} \ln(x) = \frac{1}{x}$	

Integrale		Nach dem integrieren	+ const	nicht vergessen.
$\int x^a dx = \frac{1}{a+1} x^{a+1}$	$\int a^x dx = \frac{1}{\ln(a)} a^x$			
$\int K dx = K \cdot x$	$\int \sin(x) dx = -\cos(x)$			
$\int x dx = \frac{1}{2} x^2$	$\int \cos(x) dx = \sin(x)$			
$\int \sqrt{x} dx = \frac{2}{3} x^{3/2}$	$\int \frac{1}{\sqrt{1-x^2}} dx = \arcsin(x)$			
$\int \frac{1}{\sqrt{x}} dx = 2\sqrt{x}$	$\int \frac{1}{1+x^2} dx = \arctan(x)$			
$\int \frac{1}{x} dx = \ln(x)$	$\int \ln(x) dx = x \cdot \ln(x)$			
$\int e^x dx = e^x$				

Vektorräume
Vektoren sind Listen von Zahlen.

Linearkombination
Gegeben sei eine Menge Vektoren $\{v_1, v_2, \dots, v_k\} \subset \mathbb{R}$ und eine Menge von reellen Zahlen $\lambda_1, \lambda_2, \dots, \lambda_k \in \mathbb{R}$, dann nennt man folgende Summe die Linearkombination von $\{v_1, v_2, \dots, v_k\}$

$$\sum_{i=1}^k \lambda_i v_i$$

Linear unabhängig
Falls

$$\sum_{i=1}^k \lambda_i v_i = \vec{0}$$

nur die folgende Lösung hat
 $\lambda_1 = \lambda_2 = \dots = \lambda_k = 0$

dann sind die Vektoren in $\{v_1, v_2, \dots, v_k\}$ linear unabhängig.
Linear abhängig
Falls es für obige Gleichung mehrere Lösungen gibt, dann sind die Vektoren in $\{v_1, v_2, \dots, v_k\}$ linear abhängig.

Basisvektor oder Basis
Eine Menge von linear unabhängigen Vektoren $\{v_1, v_2, \dots, v_k\}$ heisst Basis von $\mathbb{R}^n$, wenn irgendein $w \in \mathbb{R}^n$ eine Linearkombination von $\{v_1, v_2, \dots, v_k\}$ ist. In anderen Worten, wenn $\lambda_1, \lambda_2, \dots, \lambda_n$ existieren sodass folgendes gilt:

$$\sum_i \lambda_i v_i = w$$

Standard Basis
Obwohl es viele verschiedene Möglichkeiten gibt eine Basis von $\mathbb{R}^n$ zu finden, wählt man im Normalfall die Standardbasis $\{e_1, e_2, \dots, e_n\}$. Man nennt dies auch die Standardbasis von $\mathbb{R}^n$. In dieser Basis sind alle Komponenten, ausser der i -ten Komponente, 0 und die i -te Komponente ist 1.

Skalar Produkt

$$u \bullet v = u^T v = \sum_k u_k v_k$$

$$\nabla(u \bullet v) = (v^T u^T)$$

Euklidische Norm
Eine Norm $|\cdot|$ ist eine Funktion welche einem Vektor x eine positive Zahl $|x|$ zuweist, welche als Länge des Vektor x interpretiert wird.
Euklidische Norm:

$$|\cdot| : \begin{cases} \mathbb{R}^n \rightarrow \mathbb{R}^+ \\ x \mapsto \sqrt{\sum_{i=1}^n x_i^2} \end{cases}$$

$$|u| = \sqrt{u^T u} = \sqrt{\sum_k u_k^2}$$

$$\nabla|u| = \frac{1}{|u|} u^T$$

Euklidische Distanz (Metrik)
 $d(\cdot, \cdot) : \begin{cases} \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}^+ \\ (u, v) \mapsto |u - v| \end{cases}$

$$d(u, v) = |u - v|$$

$$\nabla d(u, v) = \frac{1}{d(u, v)} ((u - v)^T (v - u)^T)$$

Matrizen

Matrix Multiplikation mit einem Skalar
Bei der Multiplikation von einem Skalar $\lambda \in \mathbb{R}$ mit einer Matrix $A \in \mathbb{R}^{n \times c}$, multipliziert man einfach das Skalar λ mit jeder Komponente der Matrix

Beispiel: $2 \cdot \begin{pmatrix} 1 & 1 & 1 \\ 2 & 2 & 2 \\ 3 & 3 & 3 \end{pmatrix} = \begin{pmatrix} 2 & 2 & 2 \\ 4 & 4 & 4 \\ 6 & 6 & 6 \end{pmatrix}$

Matrix Addition
Bei der Addition (sowie auch Subtraktion) von zwei Matrizen $A, B \in \mathbb{R}^{r \times c}$, werden die Komponenten der beiden Matrizen paarweise addiert.

Beispiel: $\begin{pmatrix} 1 & 1 & 1 \\ 2 & 2 & 2 \\ 3 & 3 & 3 \end{pmatrix} + \begin{pmatrix} 1 & 1 & 1 \\ 2 & 2 & 2 \\ 3 & 3 & 3 \end{pmatrix} = \begin{pmatrix} 2 & 2 & 2 \\ 4 & 4 & 4 \\ 6 & 6 & 6 \end{pmatrix}$

Matrix Multiplikation
Bei der Multiplikation zweier Matrizen wird jeweils Zeile $\cdot$ Spalte gerechnet und dann addiert.
Es gilt:

$$C = A \cdot B \in \mathbb{R}^{l \times n}$$

$$c_{ij} = \sum_{k=1}^m a_{ik} b_{kj}$$

Beispiel: $\begin{pmatrix} 1 & 1 & 1 \\ 2 & 2 & 2 \\ 3 & 3 & 3 \end{pmatrix} \cdot \begin{pmatrix} 1 & 1 & 1 \\ 2 & 2 & 2 \\ 3 & 3 & 3 \end{pmatrix} = \begin{pmatrix} 6 & 6 & 6 \\ 12 & 12 & 12 \\ 18 & 18 & 18 \end{pmatrix}$

Matrix Transponieren
Spalten und Zeilen der Matrix werden vertauscht

$$\begin{pmatrix} 2 \\ 3 \end{pmatrix}^T = \begin{pmatrix} 2 & 3 \end{pmatrix}$$

Determinante

$$\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = a \cdot d - b \cdot c$$

Inverse
Beispiel mit Newtons Methode:

$$\begin{pmatrix} 2 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{pmatrix}$$

$$\downarrow$$

$$\begin{pmatrix} 1 & 0 & 1 & -1 \\ 0 & 1 & -1 & 2 \end{pmatrix}$$

$$\Rightarrow \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}^{-1} = \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix}$$

Rechenregeln bei Matrizen

$$A \cdot B \neq B \cdot A$$

$$A + (B + C) = (A + B) + C$$

$$A(BC) = (AB)C$$

$$A(B + C) = AB + AC$$

$$(A + B)C = AC + BC$$

$$A + B = B + A$$

$$(\lambda + \mu)A = \lambda A + \mu A$$

$$(\lambda \mu)A = \lambda(\mu A)$$

$$\lambda(B + C) = \lambda B + \lambda C$$

$$\lambda(BC) = (\lambda B)C = B(\lambda C)$$

Tensoren
Tensoren sind Grössen, mit deren Hilfe man Skalare, Vektoren sowie weitere Grössen analoger Struktur in ein einheitliches Schema einordnen kann.

- Tensoren nullter Stufe sind Skalare
- Tensoren erster Stufe sind Vektoren
- Tensoren zweiter Stufe sind Matrizen

Funktionen

Lineare Transformation
Multiplikation von einem Input Vektor x mit einer Matrix M

$$L_M : \begin{cases} \mathbb{R}^c \rightarrow \mathbb{R}^r \\ x \mapsto M \cdot x \end{cases}$$

Es gilt zudem:
 $L_M(0) = M \cdot 0 = 0$

Affine Transformation
Für viele Anwendungen reicht die lineare Transformation nicht, deshalb gibt es die affine Transformation. Um eine affine Transformation zu definieren, wird eine $r \times x$ Matrix M und ein r -dimensionaler Vektor b benötigt (in AI «bias» oder «intercept» genannt).

$$A_{b,M} : \begin{cases} \mathbb{R}^c \rightarrow \mathbb{R}^r \\ x \mapsto b + M \cdot x \end{cases}$$

Die Jacobi-Matrix einer affinen Transformation entspricht der Matrix M :

$$J A(x) = M$$

Calculus von Kurven
Die folgenden drei Sektionen «Limes», «Ableitungen» und «Linearisierung» gehen von der folgenden Ausgangslage aus:

$$f : \begin{cases} (0; \infty) \rightarrow \mathbb{R}^2 \\ t \mapsto \begin{pmatrix} \cos t \\ \sin t \end{pmatrix} \end{cases}$$

Die Komponenten dieser Funktion sind:

$$f_1(t) = \cos t$$

$$f_2(t) = \frac{\sin t}{t}$$

Limes
Der Limes wird Komponentenweise bestimmt:

$$\lim_{t \rightarrow 0} f_1(t) = 1$$

$$\lim_{t \rightarrow 0} f_2(t) = 1$$

Daraus folgt:

$$\lim_{t \rightarrow 0} f(t) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Ableitung
Die Ableitung wird Komponentenweise bestimmt:

$$\frac{d}{dt} f_1(t) = -\sin t$$

$$\frac{d}{dt} f_2(t) = \frac{\cos t}{t} - \frac{\sin t}{t^2}$$

Daraus folgt:

$$\frac{d}{dt} f(t) = \begin{pmatrix} -\sin t \\ \frac{\cos t}{t} - \frac{\sin t}{t^2} \end{pmatrix}$$

Linearisierung
Die Linearisierung wird Komponentenweise bestimmt und liefert immer eine Gerade:

$$f_1(t) \approx f_1(\pi) + f_1'(\pi)(t - \pi) = -1$$

$$f_2(t) \approx f_2(\pi) + f_2'(\pi)(t - \pi) = -\frac{1}{\pi}(t - \pi)$$

Daraus folgt:

$$f(t) \approx f(\pi) + f'(\pi)(x - \pi) = \begin{pmatrix} -1 \\ -\frac{1}{\pi}(t - \pi) \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \end{pmatrix} - (t - \pi) \begin{pmatrix} 0 \\ \frac{1}{\pi} \end{pmatrix}$$

Partielle / Totale Ableitung

Partielle Ableitung

$$\frac{\partial f}{\partial x_i}(x) = \lim_{t \rightarrow 0} \frac{f(x + t \cdot e_i) - f(x)}{t} = g_i'(0)$$

Mit $g_i'(0) = f(x + t \cdot e_i)$, wobei e_i der Einheitsvektor in Richtung i ist

Partielle Ableitung vs. Totale Ableitung

Es wird von der folgenden Funktion ausgegangen:

$$f(x, y) = 3x^2 + 2y$$

Partielle Ableitung

$$\frac{\partial f(x, y)}{\partial x} = \frac{\partial}{\partial x} (2x^2) + \frac{\partial}{\partial x} (2y) = 6x$$

Die Ableitung von $2y$ nach x fällt weg, weil y unabhängig ist von x .

Totale Ableitung

$$\frac{df(x, y)}{dx} = \frac{d}{dx} (3x^2) + \frac{d}{dx} (2y) = 6x + 2 \frac{dy}{dx}$$

Die Ableitung von $2y$ nach x fällt nicht weg, weil y abhängig ist von x .

Definitionen

Gradient

Der Gradient von f ist ein n -dimensionaler Zeilenvektor, dessen Komponenten den verschiedenen partiellen Ableitungen entsprechen.

$$\nabla f(\mathbf{x}) = \left(\frac{\partial}{\partial x_1} f(\mathbf{x}), \frac{\partial}{\partial x_2} f(\mathbf{x}), \dots, \frac{\partial}{\partial x_n} f(\mathbf{x}) \right)$$

Gradient Descent

Gradient Descent versucht minimale Punkte von f zu lokalisieren, indem man sich in die entgegengesetzte Richtung des Gradienten bewegt. λ ist dabei die Learning Rate.

$$\mathbf{x}_{i+1} = \mathbf{x}_i - \lambda \nabla f(\mathbf{x}_i)$$

Komposition zweier Funktionen

$$h(\mathbf{x}) = g \circ f = g(f(\mathbf{x}))$$

$$A \xrightarrow{f} M \subset N \xrightarrow{g} R$$

Kronecker Delta

$$\delta_{ij} = \begin{cases} 0 & \text{if } i \neq j \\ 1 & \text{if } i = j \end{cases}$$

Jacobi-Matrix

$$J_f(\mathbf{x}_0) = \begin{pmatrix} \frac{\partial x_1}{\partial x_1} f_1(\mathbf{x}_0) & \frac{\partial x_2}{\partial x_1} f_1(\mathbf{x}_0) & \dots & \frac{\partial x_n}{\partial x_1} f_1(\mathbf{x}_0) \\ \frac{\partial x_1}{\partial x_1} f_2(\mathbf{x}_0) & \frac{\partial x_2}{\partial x_1} f_2(\mathbf{x}_0) & \dots & \frac{\partial x_n}{\partial x_1} f_2(\mathbf{x}_0) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial x_1}{\partial x_1} f_m(\mathbf{x}_0) & \frac{\partial x_2}{\partial x_1} f_m(\mathbf{x}_0) & \dots & \frac{\partial x_n}{\partial x_1} f_m(\mathbf{x}_0) \end{pmatrix}$$

Hesse-Matrix

Die Hesse-Matrix entspricht der Jacobi-Matrix eines Gradienten. Sie beinhaltet also die **zweiten** partiellen Ableitungen. Die Hesse-Matrix ist **immer symmetrisch**.

$$H_f(\mathbf{x}_0) = \begin{pmatrix} \frac{\partial^2}{\partial x_1^2} f(\mathbf{x}_0) & \frac{\partial^2}{\partial x_1 \partial x_2} f(\mathbf{x}_0) & \dots & \frac{\partial^2}{\partial x_1 \partial x_n} f(\mathbf{x}_0) \\ \frac{\partial^2}{\partial x_2 \partial x_1} f(\mathbf{x}_0) & \frac{\partial^2}{\partial x_2^2} f(\mathbf{x}_0) & \dots & \frac{\partial^2}{\partial x_2 \partial x_n} f(\mathbf{x}_0) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2}{\partial x_n \partial x_1} f(\mathbf{x}_0) & \frac{\partial^2}{\partial x_n \partial x_2} f(\mathbf{x}_0) & \dots & \frac{\partial^2}{\partial x_n^2} f(\mathbf{x}_0) \end{pmatrix}$$


Quadratische Form

$$q_M : \begin{Bmatrix} \mathbb{R}^n \rightarrow \mathbb{R} \\ \mathbf{v} \mapsto \mathbf{v}^T M \mathbf{v} \end{Bmatrix}$$

Indikator Funktion

$$\chi_{[a,b]}(x) = \begin{cases} 1, & x \in [a,b] \\ 0, & x \notin [a,b] \end{cases}$$

Sigmoid Funktion



$$\sigma(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{1 + e^x}$$

$$\sigma(-x) = 1 - \sigma(x)$$

$$\sigma'(x) = \sigma(x)(1 - \sigma(x))$$

$$\sigma(0) = \frac{1}{2}$$

Softmax Funktion

$$\sigma : \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{pmatrix} \mapsto \begin{pmatrix} \frac{e^{x_1}}{\sum_{i=1}^n e^{x_i}} \\ \frac{e^{x_2}}{\sum_{i=1}^n e^{x_i}} \\ \frac{e^{x_3}}{\sum_{i=1}^n e^{x_i}} \\ \vdots \\ \frac{e^{x_n}}{\sum_{i=1}^n e^{x_i}} \end{pmatrix} \mapsto [0, 1]^n$$

Wahrscheinlichkeitstheorie

Zufallsvariablen

Es gilt $|f_Y(y)dy| = |f_X(x)dx|$, wenn $g(x)$ monoton ist (also nur steigend oder nur sinkend)

Wichtige Funktionen der Wahrscheinlichkeitsverteilung

Univariate Gleichverteilung

$$X \sim \text{unif}(a, b)$$

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{für } x \in (a, b) \\ 0 & \text{für } x < a \vee x > b \end{cases}$$

Univariate Normalverteilung

$$X \sim \mathcal{N}(\mu, \sigma^2)$$
$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$$
$$\mu \approx \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

$$\sigma^2 \approx \text{var} = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

Multivariate Normalverteilung

$$\mathbf{V} \sim \mathcal{N}(\mu, \Sigma)$$
$$f_{\mathbf{V}}(\mathbf{v}) = \frac{1}{\sqrt{(2\pi)^n \det \Sigma}} e^{-\frac{1}{2}(\mathbf{v}-\mu)^T \Sigma^{-1}(\mathbf{v}-\mu)}$$

$$\mu \approx \bar{\mathbf{v}} = \frac{1}{N} \sum_{i=1}^N \mathbf{v}_i$$

$$\Sigma \approx \mathbf{Q} = \frac{1}{N-1} \sum_{i=1}^N (\mathbf{v}_i - \bar{\mathbf{v}})(\mathbf{v}_i - \bar{\mathbf{v}})^T$$

Negatives Log Likelihood (Kostenfunktion)

$$c(\lambda, k) = -\ln((L(\lambda, k))) = -\sum_i \ln(f_{\lambda,k}(t_i))$$

Maximum Likelihood Prinzip

1. Aufstellen der Maximum-Likelihood-Funktion:

$$L(\theta) = \prod_i f_{\theta}(x_i)$$

2. Logarithmierung:

$$\ln L(\theta) = \sum_i \ln f_{\theta}(x_i)$$

3. Bestimmung der Ableitung:

$$\frac{d}{d\theta} \ln L(\theta)$$

4. Ableitung gleich 0 setzen und nach dem gesuchten Parameter (θ) auflösen.

Aufgabentypen

Approximation durch Linearisierung

- Einen »nahen« Punkt zum vorgegebenen Punkt wählen. (Bsp. $(1.1, -0.1, 0.9) \rightarrow (1, 0, 1)$)
- Jacobi-Matrix für die Funktion bestimmen.
- Den gewählten Punkt in die Jacobi-Matrix einsetzen.
- Den gesuchten Punkt approximieren:

$$\mathbf{f}(1.1, -0.1, 0.9) \approx \mathbf{f}(1, 0, 1) + \mathbf{J}_{\mathbf{f}}(1, 0, 1) \left[\begin{pmatrix} 1.1 \\ -0.1 \\ 0.9 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} \right]$$

Genauere Werte finden durch Linearisierung

- Gegebene Werte in Ursprungsfunktion einsetzen und ausrechnen.
- Jacobi-Matrix berechnen.
- Linearisierung-Funktion aufstellen. Beispiel:

$$\mathbf{f}(x, y) \approx \mathbf{f}\left(-\frac{1}{2}, -\frac{1}{4}\right) + \mathbf{J}_{\mathbf{f}}\left(-\frac{1}{2}, -\frac{1}{4}\right) \left[\begin{pmatrix} x \\ y \end{pmatrix} - \begin{pmatrix} -\frac{1}{2} \\ -\frac{1}{4} \end{pmatrix} \right]$$
$$\approx \begin{pmatrix} -\frac{1}{4} & -\frac{1}{2} \\ -\frac{1}{4} & -\frac{1}{2} \end{pmatrix} + \begin{pmatrix} 1 & e^{-\frac{1}{4}} \\ 1+e^{-\frac{1}{4}} & -e^{-\frac{1}{4}} \end{pmatrix} \begin{pmatrix} x+\frac{1}{2} \\ y+\frac{1}{4} \end{pmatrix}$$

4. Nach 0 auflösen bzw. entsprechend umstellen damit bspw. mit dem Gauss Algorithmus eine Lösung gefunden werden kann. Beispiel:

$$\mathbf{f}(x, y) = 0$$
$$\Leftrightarrow \begin{pmatrix} -\frac{1}{4} & -\frac{1}{2} \\ -\frac{1}{4} & -\frac{1}{2} \end{pmatrix} + \begin{pmatrix} 1 & e^{-\frac{1}{4}} \\ 1+e^{-\frac{1}{4}} & -e^{-\frac{1}{4}} \end{pmatrix} \begin{pmatrix} x+\frac{1}{2} \\ y+\frac{1}{4} \end{pmatrix} \approx \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$
$$\Leftrightarrow \begin{pmatrix} 1 & e^{-\frac{1}{4}} \\ 1+e^{-\frac{1}{4}} & -e^{-\frac{1}{4}} \end{pmatrix} \begin{pmatrix} x+\frac{1}{2} \\ y+\frac{1}{4} \end{pmatrix} \approx -\begin{pmatrix} -\frac{1}{4} & -\frac{1}{2} \\ -\frac{1}{4} & -\frac{1}{2} \end{pmatrix}$$

Stationäre Punkte einer vektorwertigen Funktion

- Gradient der Funktion berechnen.
- Gradient der Funktion nach 0 auflösen.
- Lösungen sind die Koordinaten der gesuchten stationären Punkte.

Maxima, Minima & Sattelpunkte bestimmen

- Hesse-Matrix der Funktion berechnen.
- Stationäre Punkte in Hesse-Matrix einsetzen.
- Quadratische Form der ausgefüllten Hesse-Matrizen berechnen, wobei M die ausgefüllte Hesse-Matrix ist.
- In der quadratischen Form überprüfen, ob es nur Vektoren $\mathbf{v}$ gibt, welche die quadratische Form positiv bzw. negativ machen oder auch solche, die beides erreichen.
- Die Hesse Matrix ist:
 - positiv definit, wenn $\mathbf{v} \in \mathbb{R}^n \setminus \{\mathbf{0}\} \Rightarrow q_M(\mathbf{v}) > 0$
 - negativ definit, wenn $\mathbf{v} \in \mathbb{R}^n \setminus \{\mathbf{0}\} \Rightarrow q_M(\mathbf{v}) < 0$
 - indefinit, wenn keiner der oberen Fälle eintritt.
- Es handelt sich beim Punkt um:
 - ein lokales Minimum, wenn die Hesse-Matrix positiv definit ist.
 - ein lokales Maximum, wenn die Hesse-Matrix negativ definit ist.
 - einen Sattelpunkt, wenn die Hesse-Matrix indefinit ist.

Beispielaufgaben

Beweise dass...

Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ und

$$\mathbf{f} : \begin{cases} \mathbb{R}^n \times \mathbb{R} \rightarrow \mathbb{R}^{n \times n} \\ \mathbf{x} \mapsto \mathbf{x} \cdot \mathbf{A} \end{cases}$$

Sei $\frac{\partial}{\partial x_{ij}} \mathbf{f}(\mathbf{X})$ die partielle Ableitung von $\mathbf{f}$ in Bezug auf das Matrixelement von $\mathbf{X}$ in Zeile i und Spalte j . Beweise, dass

$$\frac{\partial}{\partial x_{ij}} \mathbf{f}(\mathbf{X}) = \mathbf{E}_{ij} \cdot \mathbf{A}$$

wobei $\mathbf{E}_{ij}$ eine $n \times n$ -Matrix darstellt, dessen Elemente alle 0 sind außer dem einen Element in Zeile i und Spalte j .

Lösung: Wir können die partielle Ableitung von $\mathbf{f}$ komponentenweise berechnen:

Merke als erstes, dass $(\mathbf{E}_{ij})_{kr} = \delta_{ik} \delta_{jr}$ gilt.

Gemäss der Definition der Matrix Multiplikation ist das Element in Zeile k und Spalte l von $\mathbf{f}$ folgendes: $\mathbf{f}_{kl}(\mathbf{X}) = \sum_r x_{kr} a_{rl}$

Daraus folgt:

$$\frac{\partial}{\partial x_{ij}} \mathbf{f}_{kl}(\mathbf{X}) = \frac{\partial}{\partial x_{ij}} \sum_r x_{kr} a_{rl} = \sum_r \left(\frac{\partial}{\partial x_{ij}} x_{kr} \right) a_{rl} = \sum_r \delta_{ik} \delta_{jr} a_{rl} = (\mathbf{E}_{ij} \cdot \mathbf{A})_{kl}$$

Wir haben die gewünschte Aussage für die Komponente von $\mathbf{f}$ bewiesen, die in Zeile k und Spalte l liegt, und damit für alle Komponenten von $\mathbf{f}$.

Finde die Verteilfunktion

Gegeben sind $X \sim \text{unif}(0, 2)$ und $Y = e^{X^2}$. Die Aufgabe ist es die Verteilfunktion $f_Y(y)$ zu berechnen.

Es kann die folgende Formel verwendet werden:

$$|f_Y(y)dy| = |f_X(x)dx|$$

$$\frac{dx}{dy} > 0 \Leftrightarrow f_Y(y) = f_X(x) \cdot \frac{dx}{dy}$$

$$f_X(x) = \begin{cases} \frac{1}{2} & \text{für } x \in [0; 2] \\ 0 & \text{sonst} \end{cases}$$

Für $x \in [0; 2]$ befindet sich die Variable $y = e^{x^2}$ im Intervall $[1; e^4]$ und somit gilt:

$$y = e^{x^2}$$

$$\Leftrightarrow x = \sqrt{\ln(y)}$$

$$\frac{dx}{dy} = \frac{1}{2\sqrt{\ln(y)}} \cdot \frac{1}{y}$$

$$f_X(x) \frac{dx}{dy} = f_Y(y)$$

$$\Leftrightarrow f_Y(y) = \frac{1}{2y\sqrt{\ln(y)}} \cdot \begin{cases} \frac{1}{2} & \text{für } x \in [0; 2] \\ 0 & \text{sonst} \end{cases}$$

$$= \begin{cases} \frac{1}{4y\sqrt{\ln(y)}} & y \in [1; e^4] \\ 0 & \text{sonst} \end{cases}$$